

UAS Deep Learning No.3

Nama - NIM - Kelas : Nicholas Javier - 2502041956 - LA05

Link onedrive(video penjelasan semua nomor):

https://binusianorg-my.sharepoint.com/personal/nicholas_javier_binus_a_c_id/_layouts/15/guestaccess.aspx?share=ER_SwVOgwr1GgVXre8eBkjQBs8GBPPudQTa-12VatGVNXw

Link onedrive(backup):

https://binusianorg-my.sharepoint.com/personal/nicholas_javier_binus_a_c_id/_layouts/15/guestaccess.aspx?share=ER_SwVOgwr1GgVXre8eBkjQBs8GBPPudQTa-12VatGVNXw&nav=eyJyZWZlcnJhbEluZm8iOnsicmVmZXJyYWxBcHAIoiJPbmVEcm12ZUZvckJlc2luZXNzIiwicmVmZXJyYWxBcHBQbGF0Zm9ybSI6IldlYiIsInJlZmVycmFsTW9kZSI6InZpZXciLCJyZWZlcnJhbFZpZXciOiJNeUZpbGVzTGlua0NvcHkifX0&e=EZxLJy

Link youtube(video penjelasan semua nomor):

<https://youtu.be/IEJqxwOFtPM>

Adversarial Diffusion Distillation

Adversarial diffusion distillation yang biasa disingkat menjadi ADD merupakan suatu training dimana training tersebut mengenalkan score distillation. Score distillation digunakan untuk menghasilkan high fidelity dari image itu sendiri. Selain itu, loss adversarial dimana juga memiliki untuk memproduksi gambar dengan kualitas yang tinggi sehingga dapat dilihat dengan kualitas terbaiknya.

Untuk mengenal adversarial diffusion distillation lebih dalam, ada model dari diffusion yang memiliki peran besar dalam bidang pemodelan generatif dan baru-baru ini memungkinkan

kemajuan luar biasa dalam gambar berkualitas tinggi. Salah satu keunggulan dari diffusion model merupakan scalability dan iterative nature dimana dapat menanggulangi keadaan yang lebih kompleks. Untuk approach ADD, mengurangi langkah-langkah dimana mempertahankan gambar dengan kualitas tinggi dan improve gambarnya untuk menjadi lebih bagus. Ada 2 cara yaitu, adversarial loss dan distillation loss.

Generative Adversarial Networks (GANs) dan Adversarial Diffusion Distillation (ADD) keduanya merupakan pendekatan pembelajaran mesin yang menggabungkan komponen adversarial, namun keduanya berbeda dalam fokus dan metodologi. GAN menggunakan arsitektur dengan generator dan diskriminator, memanfaatkan kerugian adversarial untuk melatih generator agar menghasilkan data yang menyerupai sampel nyata. Sebaliknya, ADD memperkenalkan Distilasi Difusi Adversarial, yang memanfaatkan distilasi skor dan kerugian adversarial untuk melatih model gambar difusi secara efisien, khususnya hanya dalam 1-4 langkah pengambilan sampel, sehingga memastikan fidelitas gambar yang tinggi. Meskipun GAN dikenal luas karena kemampuan generatifnya, ADD menonjol sebagai metode yang berspesialisasi dalam sintesis gambar real-time melalui model difusi, menekankan efisiensi dan kualitas bahkan dalam rezim langkah rendah, menunjukkan kemajuan dalam pembuatan gambar satu langkah.

Metode dari ADD sendiri memiliki tujuannya untuk menghasilkan sampel dengan ketelitian tinggi dalam langkah pengambilan sampel sesedikit mungkin, sekaligus mencocokkan kualitas model canggih. Tujuan yang bersifat permusuhan tentu saja cocok untuk generasi yang cepat seperti itu melatih model yang mengeluarkan sampel pada gambar berjenis masuk satu langkah maju. Namun, upaya untuk menskalakan GAN menjadi lebih besar kumpulan data besar diamati yang penting untuk tidak semata-mata mengandalkan diskriminator, tetapi juga menggunakan pengklasifikasi terlatih atau jaringan CLIP untuk meningkatkan perataan teks.

Dalam eksperimen Adversarial Diffusion Distillation (ADD), kami menggunakan set data gambar yang relevan dan membaginya menjadi set pelatihan dan pengujian. Dengan menggunakan arsitektur ADD, kami menentukan parameter seperti jumlah langkah pengambilan sampel dan melatih model menggunakan set pelatihan. Evaluasi dilakukan pada set pengujian

dengan menghitung metrik seperti presisi, recall, F1-Score, dan akurasi. Selain itu, kami juga memantau adversarial dan score distillation losses selama pelatihan untuk memastikan konvergensi model. Hasil percobaan termasuk visualisasi gambar yang dihasilkan oleh model ADD, yang dibandingkan dengan gambar target atau gambar asli. Kami menilai sensitivitas model terhadap variasi jumlah langkah pengambilan sampel dan membandingkan kinerja ADD dengan metode generatif lainnya. Analisis waktu eksekusi berkontribusi dalam memahami kecepatan ADD, khususnya dalam konteks sintesis gambar waktu nyata. Eksperimen ini memberikan wawasan mendalam tentang kinerja, karakteristik, dan penerapan ADD dalam tugas sintesis gambar, memfasilitasi pemahaman tentang kekuatan dan area potensial untuk perbaikan.

Model ADD memungkinkan pembuatan gambar berkualitas tinggi dalam satu langkah, membuka kemungkinan baru secara real-time generasi dengan model pondasi.